Spark shell 是一个特别适合快速开发 Spark 程序的工具。即使你对 Scala 不熟悉，仍然可以使用这个工具快速应用 Scala 操作 Spark。Spark shell 使得用户可以和 Spark 集群交互，提交查询，这便于调试，也便于初学者使用 Spark。Spark shell 是非常方便的，因为它很大程度上基于 Scala REPL(Scala 交互式 shell，即 Scala 解释器)，并继承了 Scala REPL(读取-求值-打印-循环)(Read-Evaluate-Print-Loop) 的所有功能。运行 spark-shell，则会运行 spark-submit，spark-shell 其实是对 spark-submit 的一层封装。

下面是 Spark shell 的运行原理图

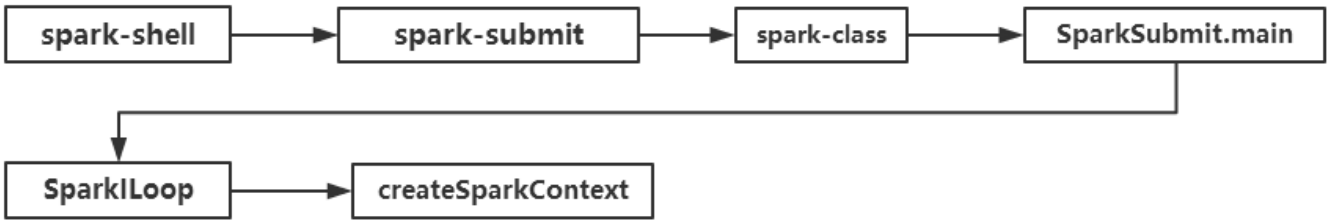

图 1: Spark shell 的运行原理图

RDD 有两种类型的操作，分别是 Transformation（返回一个新的 RDD）和 Action（返回 values）。

- Transformation：根据已有 RDD 创建新的 RDD 数据集 build

  1) map(func)：对调用 map 的 RDD 数据集中的每个 element 都使用 func，然后返回一个新的 RDD，这个返回的数据集是分布式的数据集。
  2) filter(func) ：对调用 filter 的 RDD 数据集中的每个元素都使用 func，然后返回一个包含使 func 为 true 的元素构成的 RDD。
  3) flatMap(func)：和 map 很像，但是 flatMap 生成的是多个结果。
  4) mapPartitions(func)：和 map 很像，但是 map 是每个 element，而 mapPartitions 是每个 partition。
  5) mapPartitionsWithSplit(func)：和 mapPartitions 很像，但是 func 作用的是其中一个 split 上，所以 func 中应该有 index。
  6) sample(withReplacement,faction,seed)：抽样。
  7) union(otherDataset)：返回一个新的 dataset，包含源 dataset 和给定 dataset 的元素的集合。
  8) distinct([numTasks])：返回一个新的 dataset，这个 dataset 含有的是源 dataset 中的 distinct 的 element。
  9) groupByKey(numTasks)：返回 (K,Seq[V])，也就是 Hadoop 中 reduce 函数接受的 key-valuelist。

10) reduceByKey(func,[numTasks])：就是用一个给定的 reduce func 再作用在 groupByKey 产生的 (K,Seq[V])，比如求和，求平均数。

11) sortByKey([ascending],[numTasks])：按照 key 来进行排序，是升序还是降序，ascending 是 boolean 类型。

- Action：在 RDD 数据集运行计算后，返回一个值或者将结果写入外部存储

1) reduce(func)：就是聚集，但是传入的函数是两个参数输入返回一个值，这个函数必须是满足交换律和结合律的。

2) collect()：一般在 filter 或者足够小的结果的时候，再用 collect 封装返回一个数组。

3) count()：返回的是 dataset 中的 element 的个数。

4) first()：返回的是 dataset 中的第一个元素。

5) take(n)：返回前 n 个 elements。

6) takeSample(withReplacement，num，seed)：抽样返回一个 dataset 中的 num 个元素，随机种子 seed。

7) saveAsTextFile（path）：把 dataset 写到一个 textfile 中，或者 HDFS，或者 HDFS 支持的文件系统中，Spark 把每条记录都转换为一行记录，然后写到 file 中。

8) saveAsSequenceFile(path)：只能用在 key-value 对上，然后生成 SequenceFile 写到本地或者 Hadoop 文件系统。

9) countByKey()：返回的是 key 对应的个数的一个 map，作用于一个 RDD。

10) foreach(func)：对 dataset 中的每个元素都使用 func。

获取实验测试数据

```
wget -P ./spark5 file_ip:60000/allfiles/spark5/orders
wget -P ./spark5 file_ip:60000/allfiles/spark5/order_items

wget file_ip:60000/allfiles/spark3/wordcount/buyer_favorite
wget file_ip:60000/allfiels/spark3/distinct/buyer_favorite
wget -P ./sort file_ip:60000/allfiles/spark3/sort/goods_visit

wget -P ./join file_ip:60000/allfiles/spark3/join/orders
wget -P ./join file_ip:60000/allfiles/spark3/join/order_items

wget -P ./avg file_ip:60000/allfiles/spark3/avg/goods
wget -P ./avg file_ip:60000/allfiles/spark3/avg/goods_visit
```

测试 Shell 操作

```
$ hdfs dfs -mkdir /spark5
$ hdfs dfs -put /data/spark5/orders /spark5
$ hdfs dfs -put /data/spark5/order_items /spark5
$ spark-shell
scala> val sqlContext = new org.apache.spark.sql.SQLContext(sc)
scala> import sqlContext.implicits._
scala> case class Orders(order_id:String,order_number:String,buyer_id
   :String,create_dt:String)
scala> val dforders = sc.textFile("/myspark5/orders").map(_.split('\t
   ')).map(line=>Orders(line(0),line(1),line(2),line(3))).toDF()
scala> dforders.registerTempTable("orders")
scala> sqlContext.sql("show tables").map(t=>"tableName is:"+t(0)).
   collect().foreach(println)
scala> sqlContext.sql("select order_id,buyer_id from orders").collect
scala>
scala> import org.apache.spark.sql._
scala> import org.apache.spark.sql.types._
scala> val rddorder_items = sc.textFile("/myspark5/order_items")
scala> val roworder_items = rddorder_items.map(_.split("\t")).map( p
   =>Row(p(0),p(1),p(2) ) )
scala> val schemaorder_items = "item_id order_id goods_id"
scala> val schema = StructType(schemaorder_items.split(" ").map(
   fieldName=>StructField(fieldName,StringType,true)) )
scala> val dforder_items = sqlContext.applySchema(roworder_items,
   schema)
scala> dforder_items.registerTempTable("order_items")
scala>
scala> sqlContext.sql("show tables").map(t=>"tableName is:"+t(0)).
   collect().foreach(println)
scala> sqlContext.sql("select order_id,goods_id from order_items ").
   collect
scala>
scala> sqlContext.sql("select orders.buyer_id, order_items.goods_id
   from order_items  join orders on order_items.order_id=orders.
   order_id ").collect
```

```
scala>
scala> exit
```

一些测试过程中的效果截图：

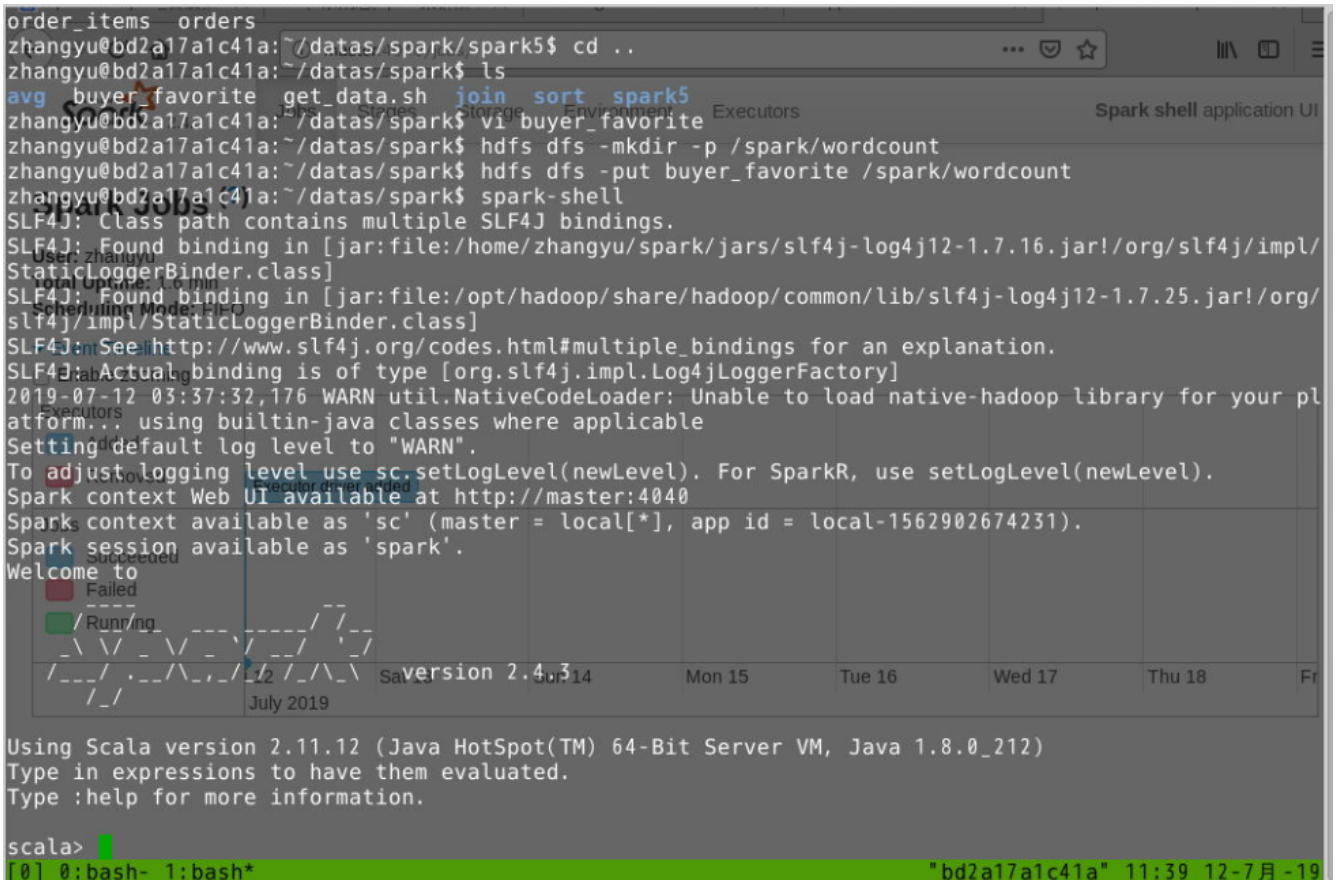

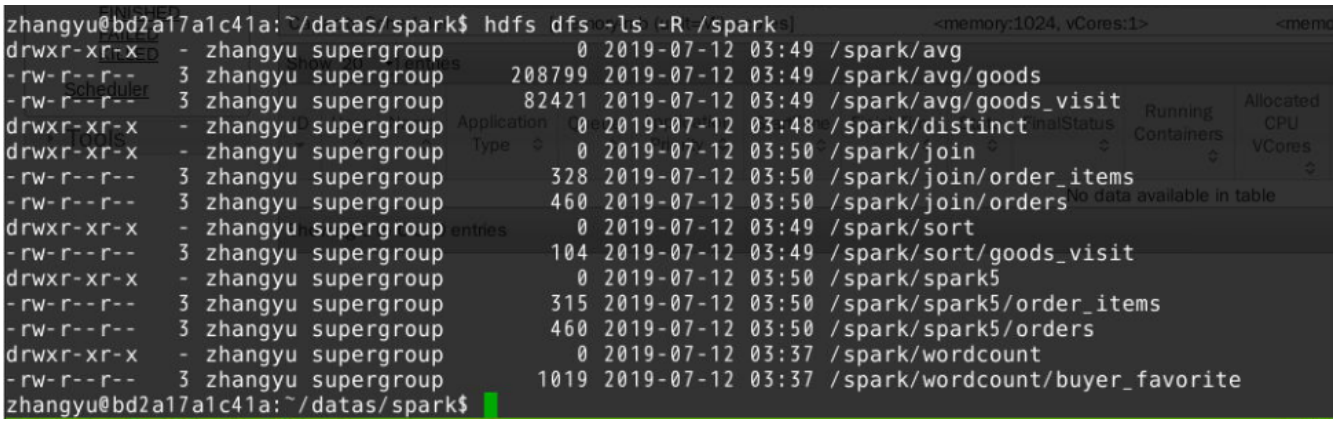

buyer_favorite

```
用户id    商品id     收藏日期
10181    1000481    2010-04-04 16:54:31
20001    1001597    2010-04-07 15:07:52
20001    1001560    2010-04-07 15:08:27
```

```
20042    1001368    2010-04-08 08:20:30
20067    1002061    2010-04-08 16:45:33
20056    1003289    2010-04-12 10:50:55
```

```
scala> rdd.map(line => (line.split('\t')(0),1)).reduceByKey(_+_).collect
res4: Array[(String, Int)] = Array((20042,1), (20055,1), (20064,1), (20054,6), (20001,2), (10181,1),
 (20067,1), (20056,12), (20076,5))

scala> rdd.map(line => (line.split('\t')(1),1)).reduceByKey(_+_).collect
res5: Array[(String, Int)] = Array((1003055,1), (1003103,2), (1001679,1), (1010675,1), (1003064,1),
(1002061,1), (1002429,1), (1003101,1), (1002427,1), (1003066,2), (1010183,1), (1000481,1), (1010178,
1), (1003290,1), (1003326,1), (1002420,2), (1003292,1), (1001368,1), (1001560,1), (1001597,1), (1003
289,1), (1002422,2), (1003094,1), (1003100,3))

scala>
```

Spark 实现 WordCount，比 Hadoop 要简单的多

```
scala> val rdd = sc.textFile("hdfs://ldcluster:8020/spark/wordcount/buyer_favorite")
rdd: org.apache.spark.rdd.RDD[String] = hdfs://ldcluster:8020/spark/wordcount/buyer_favorite MapPart
itionsRDD[1] at textFile at <console>:24

scala> rdd.count
res2: Long = 30

scala> rdd.map(line => line.split('\t')(1)).distinct.collect
res3: Array[String] = Array(1003055, 1003103, 1001679, 1010675, 1003064, 1002061, 1002429, 1003101,
1002427, 1003066, 1010183, 1000481, 1010178, 1003290, 1003326, 1002420, 1003292, 1001368, 1001560, 1
001597, 1003289, 1002422, 1003094, 1003100)

scala>
[0] 0:bash- 1:bash  2:bash*                                    "bd2a17a1c41a" 22:00 12-7月-19
```

Spark 实现去重，查看哪些商品被收藏

goods_visit

```
商品ID   点击次数
1010037  100
1010102  100
1010152  97
1010178  96
1010280  104
```

```
scala> val rdd = sc.textFile("hdfs://ldcluster:8020/spark/sort/goods_visit")
rdd: org.apache.spark.rdd.RDD[String] = hdfs://ldcluster:8020/spark/sort/goods_visit MapPartitionsRD
D[1] at textFile at <console>:24

scala> rdd.map(line => (line.split('\t')(1).toInt, line.split('\t')(0))).sortByKey(true).collect
res0: Array[(Int, String)] = Array((96,1010178), (96,1010603), (97,1010152), (97,1010637), (100,1010
037), (100,1010102), (103,1010320), (104,1010280), (104,1010510))

scala>
[0] 0:bash- 1:bash  2:bash*                                    "bd2a17a1c41a" 22:16 12-7月-19
```

Spark 对用户记录进行排序，实现按购买数升序排列。

orders

订单ID	订单号	用户ID	下单日期
52304	111215052630	176474	2011-12-15 04:58:21
52303	111215052629	178350	2011-12-15 04:45:31
52302	111215052628	172296	2011-12-15 03:12:23
52301	111215052627	178348	2011-12-15 02:37:32
52300	111215052626	174893	2011-12-15 02:18:56

order_items

明细ID	订单ID	商品ID
252578	52293	1016840
252579	52293	1014040
252580	52294	1014200
252581	52294	1001012
252582	52294	1022245

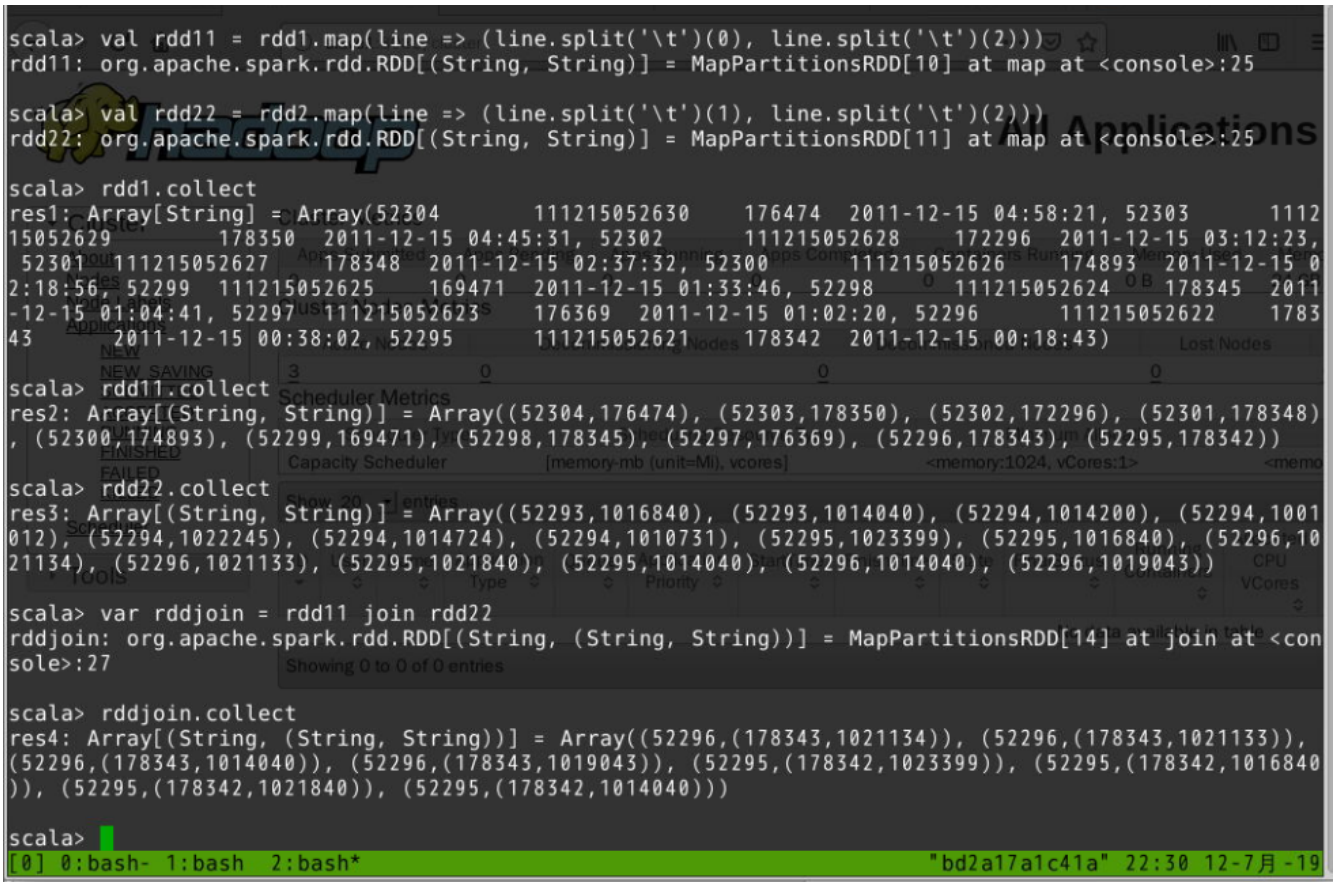

Spark 实现两张表的 Join 操作